

基于机器学习模型的量化交易策略

TASK6 课程作业

姓名：薛智鸣

研究方法：岭回归、决策树与随机森林

完成日期：2026年7月

一、机器学习交易策略的核心理念

机器学习交易策略把历史市场信息表示成一组可计算的特征，用历史上已经实现的未来收益训练模型，再用模型对尚未发生的收益、涨跌方向或风险进行预测。预测结果并不直接等于利润，而是需要经过“预测—排序—构建组合—控制成本与风险—回测验证”的完整流程才能形成交易策略。

本作业采用截面选股思路：在每个季度末利用当时可观察到的估值、规模和财务增长因子，预测每只股票下一季度收益率；将股票按预测收益排序，等权买入排名最高的 20%，持有到下一季度。

优点

1. 能同时处理大量变量，并发现线性模型不容易捕捉的非线性关系和因子交互。
2. 模型、特征和交易规则可以标准化运行，减少主观情绪影响。
3. 可以通过时间外测试、交叉验证和模型对比量化评价预测能力。
4. 随机森林等集成模型对噪声和单棵树的过拟合通常更稳健，并能输出特征重要性。
5. 同一套流程可以扩展到不同股票池、资产类别、预测周期和风险目标。

缺点

1. 金融数据噪声大、信噪比低，历史规律可能因市场状态改变而失效。
2. 随机划分或错误对齐变量容易造成前视偏差和数据泄漏，从而夸大回测结果。
3. 复杂模型容易过拟合，预测误差较低也不一定意味着可交易收益较高。
4. 回测结果受幸存者偏差、复权方式、停牌、涨跌停、流动性和交易成本影响。
5. 树模型和集成模型的经济解释性弱于传统线性因子模型。
6. 参数搜索、股票池选择和回测区间选择本身也可能带来“回测过拟合”。

二、常见自变量因子和应变量

1. 常见自变量

表1 常见机器学习量化自变量因子

因子类别	常见定义	经济含义
动量	过去 5、20、60 日累计收益	上涨或下跌趋势的延续性
反转	最近一期收益的相反数、短期超跌程度	短期价格过度反应后的修复
波动率	日收益率在滚动窗口内的标准差	价格风险和不确定性
流动性	成交额、换手率、Amihud 非流动性指标	交易是否容易及流动性溢价
估值	PE、PB、PS、EV/EBITDA、股息率	股票价格相对盈利、净资产或收入的高低
规模	总市值或流通市值的自然对数	大小盘效应及风险差异
成长	营收、净利润、净资产和 EPS 同比增长率	企业基本面扩张速度
质量	ROE、毛利率、现金流、资产负债率	盈利质量和财务稳健程度
技术指标	均线偏离、RSI、MACD、布林带位置	趋势、超买超卖与价格形态
宏观或行业	利率、汇率、通胀、行业虚拟变量	系统环境和行业差异
另类数据	新闻情绪、搜索热度、资金流、分析师预期	传统行情和财报之外的信息

实际建模时，自变量必须在预测时点已经可得。例如用季度财务数据预测下一季度收益时，应考虑财报真实披露日；如果直接按报告期末使用尚未发布的数据，会形成前视偏差。

2. 常见应变量

表2 常见机器学习量化应变量

类型	数学定义示例	用途
未来收益率	$y_{i,t} = P_{i,t+h} / P_{i,t} - 1$	回归预测未来收益大小
超额收益率	个股未来收益减市场或行业收益	预测相对表现，降低市场方向影响
涨跌标签	$1[y_{i,t} > 0]$	二分类预测上涨概率
多分类标签	按未来收益分为上涨、震荡、下跌	多分类交易信号
截面分位标签	当期未来收益排名前 20% 记为 1	直接服务于选股排序
波动率	未来窗口内日收益标准差	风险预测与仓位控制
最大回撤或尾部损失	未来窗口最差路径损失	风险预警

本作业应变量为 `Next_Ret`，定义为样本日期之后一个季度的个股收益率，是连续型回归目标。预测结果主要用于截面排序，因此除 MAE、RMSE 和 R^2 外，还重点考察 Spearman Rank IC。

三、数据、特征工程与模型设计

1. 样本加载

程序加载 `model_data.csv`，共有 39,616 条记录、10 个季度，日期范围为 2020-03-31 至 2022-06-30。每条记录由 `Date` 和 `Code` 唯一标识。

2. 原始及衍生自变量

原始变量包括 EV/EBITDA、PB、两类 PCF、两类 PE、PS、股息率、市值，以及净利润、净资产、利润总额、EPS、总资产、现金流、营业利润和营业收入增长率。

在原始变量基础上衍生：

- `log_MV`: $\log(1+MV)$ ，降低市值右偏；
- `earnings_yield`: PE 的倒数，即盈利收益率；
- `book_to_price`: PB 的倒数，即账面市值比；
- `sales_yield`: PS 的倒数，即销售收入收益率；
- `growth_composite`: 净利润、营业利润和营业总收入增长率的均值；
- `cashflow_growth_composite`: 两项现金流增长率的均值；
- `fundamental_growth_gap`: 净利润增长率减营业总收入增长率。

所有因子均在每个季度内部按 1% 和 99% 分位数缩尾并标准化。该处理只使用同一预测时点的股票截面，不使用未来季度信息。

3. 训练集、测试集与模型

- 训练集：2020-03-31 至 2021-09-30，7 个季度、26,953 条记录；
- 测试集：2021-12-31 至 2022-06-30，3 个季度、12,663 条记录；
- 岭回归：作为线性基准，使用中位数填充、稳健缩放和 L2 正则化；
- 决策树：最大深度 5，叶节点最少 100 个样本；
- 随机森林：300 棵树，最大深度 8，叶节点最少 30 个样本。

划分以完整季度为单位，不能随机打乱，否则未来季度样本可能进入训练集。

四、交易策略与测试集季度收益

每个季度按预测收益从低到高排名，选择排名最高的 20% 股票等权持有。换手率使用相邻两期持仓集合变化估算，并按 $\text{换手率} \times 0.1\%$ 扣除交易成本。基准为测试季度全部股票等权组合。

表3 测试集各季度策略收益率

模型	2021Q4	2022Q1	2022Q2	测试期累计收益
岭回归	-2.70%	6.01%	-5.10%	-2.11%
决策树	-6.12%	6.84%	-6.14%	-5.87%
随机森林	-2.21%	6.91%	-3.84%	0.52%
全市场等权基准	-8.37%	1.07%	-9.20%	-15.91%

三个模型在三个测试季度均跑赢等权基准，但绝对收益并非每季度为正。随机森林累计净值最高。

五、模型效果与回测核心指标

1. 预测效果

表4 模型测试集预测效果

模型	MAE	RMSE	R ²	Rank IC	方向准确率
岭回归	0.1866	0.2376	-0.3262	0.1483	30.75%
决策树	0.1914	0.2420	-0.3759	0.1716	29.82%
随机森林	0.1882	0.2375	-0.3249	0.2466	30.79%

三种模型的 R² 都小于 0，表明准确预测收益绝对值非常困难；但 Rank IC 为正，说明模型仍具有一定的截面排序信息。量化选股更依赖排序而不是精确点预测，因此随机森林的策略表现最好与其最高 Rank IC 相一致。

2. 回测指标

表5 策略回测核心指标

组合	累计收益	年化收益	年化波动率	夏普比率	最大回撤	正收益季度占比
岭回归	-2.11%	-2.81%	11.68%	-0.20	-5.10%	33.33%
决策树	-5.87%	-7.75%	14.98%	-0.48	-6.14%	33.33%
随机森林	0.52%	0.70%	11.59%	0.10	-3.84%	33.33%
全市场等权基准	-15.91%	-20.63%	11.41%	-1.93	-15.91%	33.33%

随机森林的累计收益、夏普比率和最大回撤均优于另外两个模型。其主要重要特征包括 EPS 增长率、盈利收益率、市值、利润总额增长率、净利润增长率和营业利润增长率，说明估值、规模与盈利成长共同影响了模型排序。

六、图形




图1 测试集累计净值

图形解读：图1显示，测试期内三种机器学习策略的净值整体均高于全市场等权基准。随机森林在2022年第一季度反弹时取得较高收益，期末净值约为1.005；尽管测试期很短，其下行幅度和最终表现仍优于岭回归与单棵决策树。




图2 各季度收益率

图形解读：图2显示，三种模型在2021年第四季度和2022年第二季度均出现绝对亏损，但亏损幅度小于等权基准；在2022年第一季度，模型策略均取得正收益。测试期超额收益主要来自下跌季度的相对抗跌能力。




图3 模型预测效果对比

图形解读：图3显示，随机森林的Rank IC最高，说明其对股票下一季度收益的截面排序能力最强；三种模型的方向准确率均较低，表明预测收益方向仍然困难。策略构建因此更适合使用相对排名，不宜把预测值直接解释为精确收益。

七、附加题：自设计随机森林基本面选股策略

附加策略选用本目录的 A 股季度截面样本，自行构造价值、规模、成长和现金流复合因子，以随机森林预测下一季度收益，并选择预测排名前 20% 的股票。测试期扣除换手成本后的累计收益为 0.52%，同期全市场等权基准为 -15.91%，累计超额约 16.43 个百分点。

该结果说明模型在下跌市场中具有一定选股能力，但不能据此断言策略长期有效：测试集只有 3 个季度，年化收益、夏普比率和胜率的统计稳定性都很弱。进一步研究应增加更长历史区间，按真实财报披露日对齐数据，加入停牌和涨跌停约束，并采用滚动训练、行业 and 市值中性化、参数稳定性检验及多档交易成本压力测试。

八、结论

机器学习能够把多个基本面因子组合成非线性的选股评分，但模型预测能力应通过严格的时间外回测判断。本样本中随机森林的 Rank IC 和策略表现最好，决策树次之，岭回归更稳定但非线性表达能力较弱。最终结果更适合视为完整的研究流程演示，而不是可直接投入实盘的收益承诺。

所有数值均由 `analyze_ml_strategy.py` 自动生成，详细逐股票预测、季度收益、模型指标、特征重要性和运行参数见 `output/`。